

MODELOS ESTADÍSTICOS PARA LA CLASIFICACIÓN DE DÍGITOS

Universidad Nacional de Colombia - Sede Medellín

Heber Esteban Bermúdez
John Bryan Yepez
Simon Zapata

23 de marzo de 2019

Resumen

En este trabajo se aborda la construcción de modelos de clasificación multiclase para predecir la clasificación de dígitos, esto se hizo usando el conjunto de datos MNIST que es una gran base de datos de dígitos escritos a mano.

Las metodologías que se abordaron para construir los modelos son las siguientes.

1. Regresión logística multinomial
2. Árboles de clasificación
3. Bosques aleatorios
4. Máquinas de soporte vectorial
5. Redes neuronales

El objetivo es validar y comparar los cinco métodos de clasificación mencionados bajo distintas configuraciones de sus parámetros o métodos para luego elegir el modelo de mejor rendimiento usando como criterio la tasa de clasificación correcta de dígitos sobre datos de prueba.

1. Definiciones

MNIST

La base de datos MNIST (base de datos modificada del Instituto Nacional de Estándares y Tecnología) es una gran base de datos de dígitos escritos a mano que se usa comúnmente para capacitar a varios sistemas de procesamiento de imágenes. La base de datos también se usa ampliamente para capacitación y pruebas en el campo del aprendizaje automático.

Modelo Estadístico

El modelado estadístico es una forma simplificada, matemáticamente formalizada para aproximarse a la realidad que genera los datos) y, opcionalmente, hacer predicciones a partir de dicha aproximación.

2. Metodología

En el presente trabajo se bordan las metodologías estadísticas más ampliamente usadas en el campo del aprendizaje automático supervisado, para entrenar distintos modelos de clasificación, con distintos métodos o configuraciones con el objetivo de clasificar dígitos del conjunto de datos MNIST. Por cada modelo mostrado y sus distintas configuraciones, se muestra el rendimiento de este haciendo uso de la tasa de clasificación correcta sobre el conjunto de datos de prueba (test) que es un subconjunto de la base original MNIST. se usó el lenguaje estadístico R para hacer estos análisis.

2.1. Análisis descriptivo

Antes de iniciar mostramos un breve análisis estadístico de las bases de datos a usar en el desarrollo del trabajo.

Dimensión de la base de datos de entrenamiento (trainingData)

Tabla 1: Dimensión de la base de datos trainingData.

Número de Filas	Número de Columnas
60000	785

Dimensión de la base de datos de prueba (testingData)

Tabla 2: Dimensión de la base de datos testingData.

Número de Filas	Número de Columnas
10000	785

Cada fila representa un dígito con la primera columna como la etiqueta de ese dígito y las columnas restantes los pixeles de este y cada observación de las variables con el valor del pixel.

A continuación en la Figura 1 se muestra la imagen de uno de los dígitos.



Figura 1: Observación 10 de la base de datos trainingData

Se uso el siguiente código para graficar la observación.

```
#Ver uno de los digitos como imagen
library(magick)
im <- function(x,m){ #Funcion para ver el digito
  plot(image_read(aperm(array(as.numeric(m[x,2:785])),c(28,28,1)),
                        c(2,1,3)))) #Muestra la imagen en el viewer
  return(m[x,1]) #Muestra el numero respectivo en consola
}
#Imagen 1 de trainingData
im(10,trainingData)
```

En la Figura 2 se muestra la distribución de los dígitos en la base de datos de entrenamiento (trainingData).




Figura 2: Distribución de los dígitos en la base de datos de entrenamiento (trainingData)

En la Figura 3 se muestra la distribución de los dígitos en la base de datos de prueba (testingData).




Figura 3: Distribución de los dígitos en la base de datos de prueba (testingData)

Se ve que la cantidad de dígitos por cada nivel tiene distribución uniforme en cada base de datos.

2.2. Regresión logística multinomial

La regresión logística multinomial generaliza el método de regresión logística para problemas multiclase, es decir, se trata de un modelo que se utiliza para predecir las probabilidades de los diferentes resultados posibles de una distribución categórica como variable dependiente, en nuestro caso tenemos 10 categorías correspondientes a los dígitos del 0 al 9.

Para este modelo se hizo uso de la librería `nnet()` de R, y se probaron 3 modelos con distintos número de iteraciones y criterio de ajuste o tolerancia 'abstol'.

A continuación se muestra el código R con el que se construyeron los modelos.

```
library(nnet)
# máximo número de iteraciones igual a 100 (por defecto)
lm_1 <- multinom(V1 ~ ., data = trainingData, MaxNWts = 7860)
# máximo número de iteraciones igual a 200 (maxit=200)
lm_2 <- multinom(V1 ~ ., data = trainingData, MaxNWts = 7860,
                 maxit = 200)
```

```
# máximo número de iteraciones igual a 200 (maxit=200) y tolerancia de 1.e-8
lm_3 <- multinom(V1 ~ ., data = trainingData, MaxNWts = 7860,
  maxit = 200, abstol = 1.e-8)
```

Los resultados de la regresión logística multinomial con número máximo de iteración igual a 100 se muestra en la Tabla 3, donde presenta un rendimiento en cuanto a tasa de clasificación correcta de dígitos del 89.76 % para la base de prueba testingData

Tabla 3: Matriz de confusión Modelo 1 - logístico multinomial

	0	1	2	3	4	5	6	7	8	9
0	920	0	1	1	3	30	16	2	6	1
1	0	1118	3	3	1	1	4	1	4	0
2	7	15	915	10	10	6	17	8	39	5
3	9	3	26	888	5	19	7	10	35	8
4	0	9	2	2	917	1	11	3	4	33
5	11	10	2	34	12	668	35	10	102	8
6	5	7	6	0	8	12	919	1	0	0
7	4	26	23	2	11	1	2	916	5	38
8	5	33	9	13	11	21	14	10	847	11
9	3	9	0	10	70	6	6	22	15	868

Los resultados de la regresión logística multinomial con número máximo de iteración igual a 200 se muestra en la Tabla 4, donde presenta un rendimiento en cuanto a tasa de clasificación correcta de dígitos del 78.63 % para la base de prueba testingData

Tabla 4: Matriz de confusión Modelo 2 - logístico multinomial

	0	1	2	3	4	5	6	7	8	9
0	745	9	47	6	5	89	16	33	14	16
1	2	1091	7	9	5	2	7	1	10	1
2	7	36	770	52	16	14	26	41	55	15
3	6	8	30	773	10	78	6	45	27	27
4	4	16	8	8	818	7	18	27	26	50
5	14	17	16	36	23	648	28	21	55	34
6	17	17	45	2	63	27	737	14	18	18
7	3	26	31	16	17	10	6	861	7	51
8	8	45	50	34	26	71	17	31	649	43
9	3	15	12	9	80	20	7	78	14	771

2.3. Árboles de clasificación

Los Árboles de clasificación son modelos de predicción que pueden usarse tanto para clasificación como para regresión, y cuyo funcionamiento se basa en la

construcción de reglas lógicas para dividir los datos entre rangos mediante condiciones.

Un ejemplo práctico es como se muestra a continuación en la Figura 4 donde se realiza un árbol de clasificación para decidir si jugar o no jugar golf con P=jugar y N= no jugar.




Figura 4: Ejemplo de árbol de clasificación

Para este modelo se hizo uso de la librería `rpart()` de R, que permite elegir entre los método “class” para clasificación, método “exp” si la variable respuesta en un objeto de supervivencia, método “poisson” si la variable respuesta tiene dos columnas.

Para este conjunto de datos en particular se hizo uso método “class”, con vector de costos constante para cada variable, a continuación se muestra el código R para el modelo.

```
library(rpart)
# Árboles de clasificación con los metodos class
modelo1_rpart <- rpart(V1 ~ ., data = trainingData, method = "class")
```

En Tabla 5 se muestra la matriz de confusión obtenida con el modelo de árboles de regresión y método class sobre el conjunto de datos de prueba `testingData`, en la diagonal principal de la matriz se observan las clasificaciones correctas por cada dígito, donde se puede concluir que el rendimiento de este modelo en cuanto a tasa de clasificación de observaciones correctas es de aproximadamente 61 %

Tabla 5: Matriz de confusión Árboles de clasificación método class										
	0	1	2	3	4	5	6	7	8	9
0	793	4	1	9	6	35	52	55	10	15
1	2	964	35	56	0	0	0	10	67	1
2	72	83	511	61	19	1	54	82	134	15
3	23	20	35	651	7	101	23	20	110	20
4	5	32	6	13	608	30	103	61	59	65
5	70	30	8	100	53	221	125	21	191	73
6	33	39	50	35	69	36	570	38	84	4
7	2	14	36	6	31	24	5	793	61	56
8	12	76	38	75	21	131	64	6	519	32
9	6	17	2	17	39	125	44	86	107	566

2.4. Bosques aleatorios

La clasificación con Bosques Aleatorios implica la construcción de una gran cantidad de árboles de clasificación sobre un el conjunto de datos y por tanto incurre en un gran gasto computacionalmente.

En la Figura 5 se muestra que un Bosque aleatorio es una construcción de varios árboles de clasificación como se mostró en el ejemplo anterior.




Figura 5: Ejemplo de Bosque aleatorio.

Donde X representan las variables regresaras o datos de entrada y Y los datos de salida o respuesta del modelo.

Para implementar el Random Forest sobre nuestros datos MNIST se empleo la función `randomForest` del paquete `randomForest` con 10, 100 y 200 árboles, los resultados se muestran a continuación.

El código empleado para la construcción de los modelos es como sigue.

```
# cargando libreria al ambiente de trabajo
library(randomForest)
# construccion con 10 árboles
clasificadorRF1 <- randomForest(V1 ~ ., data = trainingData, ntree = 10)
clasificadorRF2 <- randomForest(V1 ~ ., data = trainingData, ntree = 100)
clasificadorRF3 <- randomForest(V1 ~ ., data = trainingData, ntree = 200)
```

Con 10 árboles se obtiene una tasa de clasificación correcta de dígitos de aproximadamente el 94.91 % para los datos de prueba testingData como se muestra en la Tabla 6.

Tabla 6: Matriz de confusión Bosques aleatorios con 10 árboles

	0	1	2	3	4	5	6	7	8	9
0	967	1	1	1	0	2	5	1	2	0
1	0	1117	4	2	0	2	4	1	4	1
2	6	2	976	7	5	3	8	13	9	3
3	2	1	12	949	0	20	3	11	11	1
4	1	1	4	0	930	1	8	1	10	26
5	6	1	4	28	6	826	8	1	7	5
6	10	3	5	0	6	12	918	0	4	0
7	3	7	21	5	4	1	0	961	5	21
8	5	1	6	14	9	15	8	2	903	11
9	3	5	3	11	19	5	2	4	13	944

Los resultados obtenidos usando 100 árboles nos muestra que para el conjunto de validación se obtiene una tasa de clasificación de observaciones correctas del 96,92 % para los datos de prueba testingData como se muestra en la siguiente matriz de confusión ver Tabla 7.

Tabla 7: Matriz de confusión Bosques aleatorios con 100 árboles

	0	1	2	3	4	5	6	7	8	9
0	972	1	1	0	0	2	2	1	1	0
1	0	1124	2	3	0	2	2	0	1	1
2	6	0	999	6	2	1	2	10	6	0
3	1	0	11	967	0	10	0	10	10	1
4	2	0	0	0	957	0	5	0	2	16
5	2	0	1	9	2	865	4	1	6	2
6	9	3	0	0	4	5	932	0	5	0
7	1	3	21	0	0	0	0	991	3	9
8	4	0	6	11	6	4	4	3	925	11
9	5	6	1	10	13	2	1	5	6	960

Los resultados obtenidos para un conjunto de 200 árboles se muestra a continuación (ver Tabla 8). y presenta 97.1 % de tasa de clasificación correcta de dígitos sobre la base de datos de prueba testingData.

Tabla 8: Matriz de confusión Bosques aleatorios con 200 árboles

	0	1	2	3	4	5	6	7	8	9
0	968	0	0	0	0	2	4	1	4	1
1	0	1123	3	3	0	2	2	0	1	1
2	6	0	998	6	3	0	4	9	6	0
3	0	0	7	977	0	7	0	9	8	2
4	1	0	0	0	956	0	5	0	3	17
5	2	0	1	13	3	860	4	2	5	2
6	7	3	0	0	3	4	936	0	5	0
7	1	3	18	2	0	0	0	990	2	12
8	3	0	5	7	4	6	3	4	935	7
9	5	5	2	8	9	1	1	4	7	967

Se observa que a medida que aumentamos el número de árboles aumenta la precisión del modelo en cuanto a tasa de clasificación correcta para los datos de prueba testingData.

2.5. Máquinas de soporte vectorial

Las Máquinas de soporte vectorial son modelos capaces de generar clasificaciones de datos no lineales a partir de la transformación de los datos de entrada a otros espacios de mayores dimensiones, con fin de encontrar una dimensión donde las observación serán separables de la mejor manera, Las SVM busca encontrar aquella curva que sea capaz de separar y clasificar los datos de entrenamiento garantizando que la separación entre ésta y ciertas observaciones del conjunto de entrenamiento (los vectores de soporte) sea la mayor posible, aunque esta metodología es más recomendada para clasificación binaria, en este ejemplo de la clasificación de dígitos la usaremos esta metodología como un modelo multiclase.

En la Figura 6 se muestra la ilustración del objetivo de las máquinas de soporte vectorial el cual es encontrar la una recta en el caso de 2 dimensiones donde las observaciones divididas en 2 clase sean separables de la mejor manera posible.




Figura 6: Ejemplo de maquina de soporte vectorial.

La clase 1 es representada con el color azul y la clase 2 con el color verde en función de dos variables regresoras x_1 y x_2 .

Los métodos usados en las SVM son el kernel 'linear', 'polynomial', 'sigmoid' y 'radial basis' se compararán los primeros 2 métodos con costo de violación de las restricciones constantes en 1 y con criterio de tolerancia de terminación (por defecto: 0.001).

El código empleado para la creación de los modelos se muestra a continuación.

```
# cargando la librería al ambiente de trabajo
library(e1071)
# hacemos uso de la función svm con kernel lineal y tipo clasificación
clasificadorSVM_lineal <- svm(V1 ~ ., data = trainingData,
                              type = 'C-classification', kernel = 'linear')

# hacemos uso de la función svm con kernel polynomial y tipo clasificación
clasificadorSVM_polynomial <- svm(V1 ~ ., data = trainingData,
                                   type = 'C-classification', kernel = 'polynomial')
```

Para el método 'linear' se obtuvo una tasa de clasificación correcta del 90.86 % la matriz de confusión se muestra a continuación (ver Tabla 9).

Tabla 9: Matriz de confusión Máquinas de soporte vectorial método 'linear'

	0	1	2	3	4	5	6	7	8	9
0	940	0	4	3	2	11	10	3	2	5
1	0	1109	1	2	0	1	5	0	17	0
2	7	7	905	29	12	4	17	12	35	4
3	2	2	19	901	1	27	3	14	25	16
4	1	0	4	0	914	0	13	7	2	41
5	7	7	6	42	5	747	18	3	43	14
6	7	2	9	1	6	9	918	0	6	0
7	0	8	21	7	7	0	0	910	11	64
8	10	5	10	27	9	27	8	5	855	18
9	3	6	1	6	46	9	0	39	12	887

Para el método 'polynomial' se obtuvo una tasa de clasificación correcta del 97.91 % la matriz de confusión se muestra a continuación (ver Tabla 10)

Tabla 10: Matriz de confusión Máquinas de soporte vectorial método 'polynomial'

	0	1	2	3	4	5	6	7	8	9
0	972	0	1	0	0	3	1	0	2	1
1	0	1124	2	1	1	2	3	0	2	0
2	7	0	1006	0	2	1	5	7	3	1
3	0	2	1	987	0	6	0	5	6	3
4	2	0	2	0	965	0	3	1	0	9
5	2	0	0	7	1	870	3	0	4	5
6	4	5	1	0	3	6	937	0	2	0
7	0	9	9	2	2	0	0	1000	0	6
8	5	0	1	2	4	4	1	4	950	3
9	3	5	0	3	9	4	1	1	3	980

Se puede observar que el modelo con kernel 'polynomial' presenta mayor rendimiento que el modelo con kernel 'linear' en cuanto a tasa de clasificación correcta para el conjunto de datos de prueba.

2.6. Redes neuronales

Una red neuronal convolucional es un tipo de red neuronal artificial donde las neuronas corresponden a campos receptivos de una manera muy similar a las neuronas en la corteza visual primaria de un cerebro biológico, estas son muy efectivas para tareas de visión artificial, como en la clasificación y segmentación de imágenes, entre otras aplicaciones, en este desarrollo probaremos dos diferentes configuraciones de redes neuronales convolucionales.

En la Figura 7 se muestra una estructura de una red neuronal con 2 capas ocultas nodos de color verde y cuatro variables de entrada nodos de color rojo y tres variables respuesta color morado.




Figura 7: Estructura de una Red neuronal Artificial

Para el desarrollo de este trabajo se hizo uso de la librería keras de R para el manejo de redes neuronales artificiales.

Para la primera configuración de la red se tomó para la capa de entrada 10 nodos uno por cada dígito o clase y se usaron dos capas ocultas una con 512 nodos y la otra con 128 nodos agregando como función de activación 'relu' para cada capa oculta, para esta arquitectura se usó el modelo secuencial del keras. La última capa agregada consta de conexiones para las 10 clases y con función de activación 'softmax' que es propia para los objetos multiclase y para la compilación de la red se usa función de pérdida o función objetivo `categorical_crossentropy` que es la más adecuada para este tipo de problemas y por último para el entrenamiento del modelo se usaron 100 épocas.

NOTA: La normalización de los datos de entrada es muy importante ya que nos ayuda a acelerar el entrenamiento del modelo y reduce la posibilidad de que el método del gradiente que se usa en redes neuronales se atasque en óptimos locales. El código usado para el modelo se muestra a continuación.

```
library(keras)
model1 <- keras_model_sequential() %>%
  layer_dense(512, input_shape=c(784, NULL), activation = 'relu') %>%
  layer_dropout(0.2) %>%
  layer_dense(128, activation = 'relu') %>%
  layer_dropout(0.2) %>%
  layer_dense(10, activation = 'softmax') %>%
```

```

compile(loss='categorical_crossentropy', metrics='accuracy', optimizer='adam')

# Entrenar primer modelo
history1 <- model1 %>%
  fit(trainingData,
      trainLabels,
      epochs = 100,
      batch_size = 2048,
      validation_split = 0.2)
#validation_data = list(test, testLabels))

```

En la Tabla 11 se muestran los resultados del primer modelo de redes neuronas que presenta un rendimiento en cuanto a tasa de clasificación de observaciones correctas del 98.01 %

Tabla 11: Matriz de confusión Redes Neuronales Modelo 1

	0	1	2	3	4	5	6	7	8	9
0	973	0	4	1	1	2	3	0	4	2
1	1	1127	2	0	0	0	2	6	0	3
2	0	1	1008	3	3	0	0	6	3	0
3	1	1	2	990	0	6	1	3	6	3
4	1	0	3	0	962	1	4	2	3	7
5	2	1	0	5	0	873	4	0	5	5
6	1	2	0	0	3	5	942	0	2	0
7	1	0	7	6	0	0	0	1005	4	7
8	0	3	5	4	1	2	2	2	946	7
9	0	0	1	1	12	3	0	4	1	975

Para el segundo modelo también se usó el modelo secuencial de keras y con segunda capa MaxPooling. La capa MaxPooling se utiliza para muestrear la entrada para permitir que el modelo haga suposiciones sobre las características para reducir el ajuste excesivo. También reduce la cantidad de parámetros a aprender, reduciendo el tiempo de entrenamiento. luego se agrega una capa más oculta con 32 filtros o canales de salida con el tamaño de 3 3 y una función de activación 'relu', también se agrega una capa de regularización que utiliza que está configurado para excluir al azar el 20% de las neuronas en la capa para reducir el sobreajuste, luego se agrega una capa completamente conectada con 128 neuronas y por último la capa de salida con 10 neuronas (número de clases de salida) y utiliza la función de activación de softmax. Cada neurona dará la probabilidad de esa clase.

Finalmente, para compilar el modelo se usa categorical_crossentropy como una función de pérdida porque es un problema de clasificación multiclase.

En el entrenamiento del modelo se ajustó a más de 10 épocas y se actualiza después de cada 200 imágenes de entrenamiento, a continuación se muestra el código empleado para la construcción de modelo de red neuronal

```

model2 <- keras_model_sequential() %>%
  layer_conv_2d(filters = 32, kernel_size = c(5,5),
    input_shape = c(28,28,1), activation = 'relu') %>%
  layer_max_pooling_2d(pool_size=c(2, 2)) %>%
  layer_conv_2d(filters = 32, kernel_size = c(3,3),
    activation = 'relu') %>%
  layer_max_pooling_2d(pool_size=c(2, 2)) %>%
  layer_dropout(0.2) %>%
  layer_flatten() %>%
  layer_dense(128, activation='relu') %>%
  layer_dense(10, activation='softmax') %>%
  compile(loss='categorical_crossentropy', optimizer='adam',
    metrics=c('accuracy'))

# Entrenar segundo modelo
history2 <- model2 %>%
  fit(trainingData2D,
    trainLabels,
    validation_split = 0.2,
    epochs=10,
    batch_size=200)

```

En la Tabla 12 se muestran los resultados del segundo modelo de redes neuronas que presenta un rendimiento en cuanto a tasa de clasificación de observaciones correctas del 98.84%

Tabla 12: Matriz de confusión Redes Neuronales Modelo 2

	0	1	2	3	4	5	6	7	8	9
0	972	1	1	0	1	0	3	0	4	0
1	1	1121	0	0	0	0	2	0	1	0
2	2	4	1024	0	0	0	1	2	4	0
3	0	0	1	1004	0	10	0	1	2	1
4	0	0	0	0	971	0	3	0	0	5
5	0	1	0	2	0	880	3	0	2	4
6	3	4	0	0	5	2	944	0	0	1
7	1	2	6	3	2	0	0	1021	1	3
8	1	2	0	1	0	0	2	1	954	2
9	0	0	0	0	3	0	0	3	6	993

2.7. Comparación de los modelos

A continuación en la Tabla 13 se muestra la comparación de los modelos evaluando el rendimiento en cuanto a tasa de clasificación de observaciones correctas para los datos de prueba de todos los modelos multiclase tratados en este trabajo.

Tabla 13: Tabla comparativa de modelos de clasificación

Metodología	Modelo	Tasa de clasificación correcta
Regresión logística multinomial	Modelo 1	89.76 %
	Modelo 2	78.63 %
Arboles de clasificación	Modelo 1	61 %
	Modelo 1	94.91 %
	Modelo 2	96,92 %
Bosques aleatorios	Modelo 3	97.1 %
	Modelo 1	90.86 %
Máquinas de soporte vectorial	Modelo 2	97.91 %
	Modelo 1	98.01 %
Redes Neuronales	Modelo 2	98.84 %
	Modelo 1	98.84 %

El modelo con mejor rendimiento es el segundo modelo de redes neuronales con una tasa de clasificación correcta para los dígitos del 98.84 %

3. Clasificar cartas

La arquitectura básica para explotar el segundo modelo de redes neuronales en la práctica de leer códigos postales y clasificar cartas se muestra a continuación (Ver Figura 8).

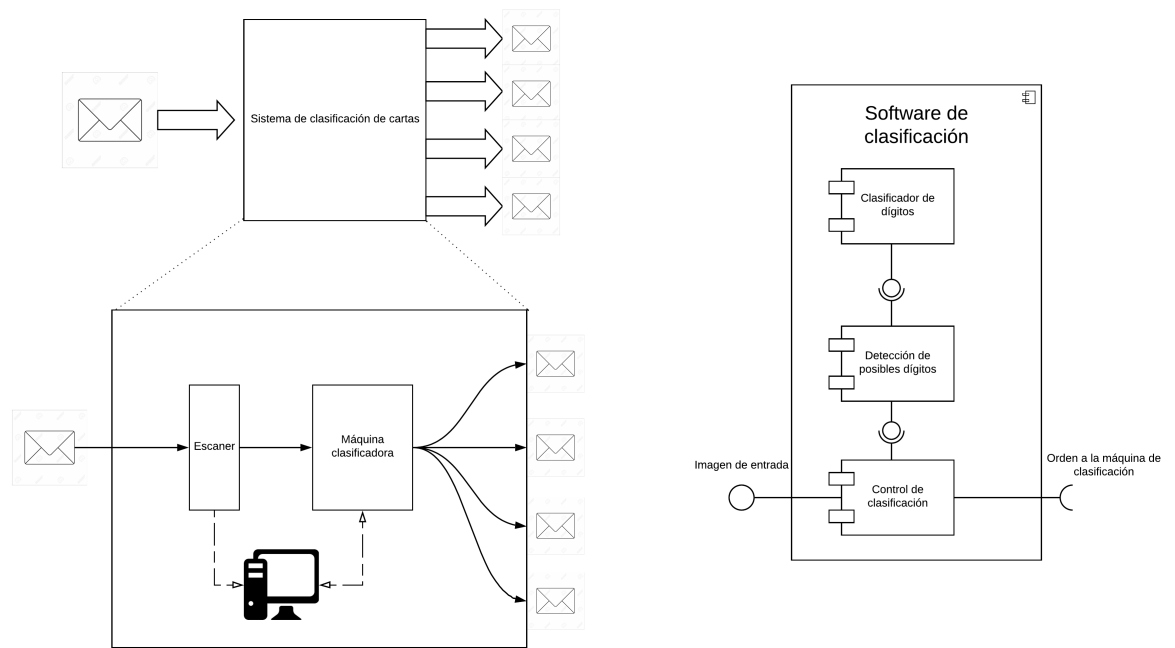


Figura 8: Leer códigos postales y clasificar cartas

Se propone un sistema de clasificación de cartas que recibe las cartas por una entrada, las clasifica y las devuelve por diferentes salidas dependiendo de su código postal.

El sistema consiste en

- Un sistema de bandas transportadoras que lleva las cartas a través del sistema.
- Un escáner, que digitaliza el código postal.
- Una máquina clasificadora, que envía la carta por el camino adecuado mediante un sistema de bandas transportadoras.
- Una computadora conectada al escáner y a la máquina clasificadora, que controla dicha máquina haciendo uso de un software de clasificación.

El software de clasificación contiene los siguientes componentes:

- Un proceso de control de clasificación: recibe la imagen desde el escáner, y controla la máquina clasificadora. El control de clasificación llama a un proceso de detección de dígitos para que le traduzca el código postal.
- El proceso de detección de dígitos: detecta los posibles dígitos separados de la imagen, y solicita a un proceso clasificador de dígitos que le clasifique dicho dígito. Con todos los dígitos obtenidos arma el código postal para enviarlo al control de clasificación.
- El proceso clasificador de dígitos: hace uso del modelo de clasificación de redes

neuronales (Modelo 2) para clasificar cada imagen como un dígito, y devolverle dicho dígito al proceso de detección de dígitos.

4. Repositorio

Repositorio en GitHub con el código R del trabajo y el Informe.
<https://github.com/hebermudezg/Clasificacion-de-digitos-MNIST>

5. Conclusiones

Las redes neuronales resultan ser una de las herramientas mas poderosas en el tema de clasificación de imágenes puesto que presentan un rendimiento muchas veces mejor que otras metodologías convencionales de clasificación tanto así que el análisis de imágenes con redes neuronales representa un campo en pleno auge llamado visión artificial, donde se estudia estas metodologías para llevarlas a la industria de manera eficiente como por ejemplo en la conducción autos autónomos que reconocen el ambiente que los rodea mediante redes neuronales que procesan imágenes para ser muy seguros.

6. Bibliografía

Introducción a los Modelos de Clasificación en R

tomado de: <https://rpubs.com/rdelgado/397838>

Redes neuronales convolucionales

tomado de: https://es.wikipedia.org/wiki/Redes_neuronales_convolucionales

MNIST Handwritten Digit Recognition in Keras

tomado de: <https://nextjournal.com/gkoehler/digitrecognitionwithkeras>

Handwritten Digit Prediction using Convolutional Neural Networks

tomado de: <https://medium.com/coinmonks/handwrittendigitprediction-usingconvolutionalneuralnetworksintensorflowwithkerasandlive5ebddf46dc8>

RStudio Team: (2019). Integrated Development for R. RStudio, Inc., Boston, MA URL

<http://www.rstudio.com/>.